

Stéphane Fons



Mission export
Expansion internationale

- ✓ Analyse des pays
- ✓ Données FAO
- ✓ ACP & réduction des dimensions
- ✓ Clustering (k-means)
- ✓ Préconisations COMEX



Tous les pays
sont envisageables !



Contexte et objectif de la mission

Objectif business

Identifier des groupes de pays prometteurs pour une future stratégie d'exportation de volaille.

Approche data

Construire un dataset pays à partir d'indicateurs alimentaires, démographiques, économiques et politiques.

Finalité

Préparer une base fiable pour l'ACP, le clustering et les recommandations destinées au COMEX

Démarche retenue

- ▶ Analyser les fichiers sources disponibles
- ▶ Sélectionner les variables pertinentes
- ▶ Nettoyer et fiabiliser le périmètre pays
- ▶ Produire un dataset final prêt pour l'analyse multivariée

En clair



Ce premier notebook sert à construire une base de travail propre, cohérente et exploitable. Il prépare les données qui seront ensuite utilisées dans le second notebook pour segmenter les pays et aider à la décision



Analyses exploratoires des données

Sources principales :

Disponibilité alimentaire (FAO)

- ▶ 176,600 lignes
- ▶ 14 colonnes
- ▶ Données par pays / produit / indicateur / année

Population

- ▶ 4411 lignes
- ▶ 15 colonnes
- ▶ Données par pays et par année

Caractéristiques

- ▶ Clé commune : Zone
- ▶ Base utilisée pour une analyse par pays
- ▶ Sources cohérentes pour démarrer l'étude

Contrôle qualité initial

Disponibilité alimentaire

- ▶ Aucune valeur manquante visible sur les colonnes utiles
- ▶ Structure exploitable dès le départ

Population

- ▶ La colonne note contient des valeurs manquantes. Cette colonne n'est pas utilisée pour l'analyse le reste du fichier est exploitable.

Lecture

Les deux fichiers sont bien structurés et complémentaires

Point d'attention

Le périmètre pays diffère entre les sources et devra être harmonisé.



En clair

Les deux fichiers sont exploitables pour démarrer le projet. Ils fournissent une base solide pour construire un dataset pays utile à la future analyse des marchés à l'international.



Nettoyage du périmètre pays

Couverture observée



- 135 pays complets
- 37 pays incomplets

Répartition :

- 2 pays avec 4 indicateurs
- 2 pays avec 6 indicateurs
- 33 pays avec 7 indicateurs
- 135 pays avec 8 indicateurs

Territoires à surveiller



- Petites îles et micro-territoires
- Faible population
- Données insuffisantes
- Intérêt stratégique limité

Exemples :

Saint-sièges, Tokélaou, Nioué, Tuvalu, Nauru

Décision méthodologique



- Conserver un périmètre comparable
- écarter les territoires peu exploitables
- limiter les biais pour l'analyse statistique



Tous les pays ne sont pas exploitables de la même manière.
Le nettoyage du périmètre permet d'obtenir une base plus fiable et cohérente pour la suite

Construction du dataset pays

Données sources

- Données FAO en format long
- Plusieurs lignes par pays
- Une ligne correspond à

Un produit + 1 indicateur + 1 années par ligne

Zone	Élément
Afghanistan	Production
Afghanistan	Importations - Quantité
Afghanistan	Disponibilité intérieure
Afghanistan	Disponibilité alimentaire en quantité (kg/personne/an)
Afghanistan	Disponibilité alimentaire (Kcal/personne/jour)

Chaque indicateur est stocké en ligne. Le même pays apparaît plusieurs fois.

Transformation : le pivot

- les indicateurs (lignes sont transformés en colonnes
- On regroupe toutes les infos d'un pays sur une seule ligne
- Chaque pays devient une observation unique

Le pivot transforme les indicateurs en colonnes :

1 ligne = 1 pays | 1 colonne = 1 variable

Dataset pays obtenu

- 1 ligne = 1 pays
- 1 colonne = 1 variable
- Population 2017 intégrée

Zone	Disp. kcal	Disp. qté	Disp. int.	Exp.	Imp.	Prod.	Pop. 2017
Afrique du Sud	143.00	35.69	2118	63.00	514.00	1667	57.01 millions
Albanie	85.00	16.36	47.00	0.00	38.00	13.00	2.88 millions
Algérie	22.00	6.38	277.00	0.00	2.00	275.00	41.39 millions
Allemagne	71.00	19.47	1739	646.00	842.00	1514	82.66 millions



En clair

Cette étape transforme des données brutes hétérogènes et répétées en un tableau structuré

Chaque pays = une observation complète, comparable avec les autres pays

Enrichissement économique et politique du dataset

Sources complémentaires

- Banque mondiale : PIB 2017
- Banque mondiale : Stabilité politique 2017
- Données externes ajoutées au dataset pays
- Même logique de lecture : 1 ligne = 1 pays

Ces variables apportent une lecture
Économique et institutionnelle
Complémentaire aux données alimentaires

Données sources

- Sélection de l'année 2017 pour garder une base cohérente
- Harmonisation des noms de pays entre les sources
- Jointure avec le dataset construit à l'étape précédente
- Vérification des valeurs manquantes et de la cohérence

Objectif : enrichir le dataset sans
Casser sa structure

Dataset enrichi

- Variables ajoutées : PIB_2017 et stabilité_politique_2017
- Variables dérivées créées :
 - taux_dependance_importations
 - balance_commerciale_quantite
 - PIB_par_habitant
- Calcul du PIB_par_habitant à partir du PIB et de la population
- Lecture économique plus complète du potentiel marché
- Base prête pour l'ACP puis le Clustering

En clair :

Le dataset ne contient plus
seulement des données
alimentaires.
Il intègre aussi des variables
économiques, politiques et
des indicateurs dérivés
pour mieux comparer le
potentiel réel des pays.





Pourquoi utiliser l'ACP ?

Une étape clé pour simplifier, comprendre et préparer le clustering

Problème de départ

- Beaucoup de variables à analyser en même temps
- Variables dérivées créées
- Certaines variables sont corrélées ou redondantes
- Comparer les pays devient moins lisible

Transformation réalisée

Disponibilité alimentaire

Importations

Production

PIB

Stabilité politique

+ Autres variables

ACP

PC1

PC2

PC3

PC4

L'ACP transforme plusieurs variables métier en quelques
Composantes principales plus faciles à lire

Rôle de l'ACP

- Réduire la complexité du dataset
- Résumer l'information en quelques axes
- Conserver l'essentiel de la variabilité
- Lecture économique plus complète du potentiel marché
- Base prête pour l'ACP puis le Clustering

Pourquoi avant le clustering ?

- Éviter de travailler sur trop de variables à la fois
- Réduire l'effet des redondances entre indicateurs
- Faciliter la projection des pays sur PC1 / PC2
- Obtenir une base plus compacte pour le CAH et le K-Means

Variance expliquée



- Les premiers axes concentrent l'information la plus utile

Ce que produit l'ACP

- Des composantes principales (PC1 à PC4)
- Un plan factoriel pour visualiser les pays
- Un pourcentage de variance expliquée par axe
- Une lecture plus synthétique des profils de pays

Choix du nombre d'axes ACP



Pourquoi choisir le nombre d'axes?

- Chaque axe ACP résume une partie de l'information initiale
- Trop peu d'axes = perte d'information
- Trop d'axes = réduction de dimension moins utile
- L'objectif est de garder un bon **compromis** entre **simplicité** et **richesse d'information**



Ce qu'on regarde


- Beaucoup de variables à analyser en même temps
- Variables dérivées créées
- Certaines variables sont corrélées ou redondantes
- Comparer les pays devient moins lisible



Choix retenu

- 4 axes conservés
- **PC1** et **PC2** servent bien à la visualisation
- Les axes supplémentaires complètent l'information utile
- Ce choix prépare un ACP lisible et exploitable pour le clustering

Variance expliquée par les axes



Axe	% variance	Cumul
PC1	32,49	32,49
PC2	21,90	54,39
PC3	14,85	69,24
PC4	12,49	81,73




En clair

On ne garde pas tous les axes de l'ACP. On retient ceux qui résument suffisamment l'information pour analyser les pays sans alourdir la lecture. Ici, 4 axes constituent un compromis pertinent entre synthèse, interprétation et préparation du clustering.

Lecture des variables : cercle des corrélations

Cercle des corrélations - PC1 / PC2



Comment lire le graphique ?

- Chaque flèche représente une variable du dataset
- plus la flèche est proche du cercle, mieux la variable est représentée
- 2 flèches opposées traduisent une opposition entre variables



Variables bien représentées

- Disponibilité alimentaire (Kcal et kg/an)
- PIB par habitant
- Importations, exportations et PIB total
- Population, production et disponibilité intérieure
- Population, production et disponibilité intérieure
- Stabilité politique



Lecture des axes (PC1) :

Le cercle montre que PC1 est surtout structuré par les variables de volume économique et commercial : importations, exportations, exportation, PIB total, production et disponibilité intérieure pointent globalement vers la droite. À l'inverse, la balance commerciale et la dépendance aux importations se situent de l'autre côté, ce qui traduit une logique différente.



Interprétation de PC2 :

Le deuxième axe oppose d'avantage les variables de niveau de vie et de contexte institutionnel. Comme la stabilité politique, le PIB par habitant et les disponibilités alimentaires aux variables d'avantage liées au poids démographique ou aux volumes internes, comme la population ou la disponibilité intérieure.




En clair :

Le cercle des corrélations permet de donner du sens aux axes de l'ACP. Ici, il montre que les premières composantes résument à la fois des différences de puissance économique, d'échanges commerciaux, de niveau alimentaire et de contexte politique. Cette lecture facilitera ensuite l'interprétation des clusters.

Projection des pays sur le plan factoriel

Projection des pays sur PC1 / PC2 avec pays les plus éloignés



Comment lire le graphique ?

- Chaque point représente un pays
- Deux pays proches ont des profils similaires
- Plus un pays est éloigné du centre, plus son profil est atypique
- Le plan PC1/PC2 résume déjà 54,39% de l'information totale



Variables bien représentées

- Une grande partie des pays reste regroupée autour du centre
- Certains pays se distinguent nettement sur l'axe PC1
- D'autres se différencient sur l'axe PC2
- Population, production et disponibilité intérieure
- La dispersion confirme l'existence de profils pays variés



Lecture des axes :

Sur l'axe horizontal (PC1), les pays situés à droite sont plutôt associés à des volumes économiques et commerciaux plus élevés : importations, exportations, PIB total, production ou disponibilité intérieure. Sur l'axe vertical (PC2), les pays situés en haut sont d'avantage liés à un meilleur niveau de vie et à un contexte plus favorable : PIB par habitant, stabilité politique...



Pourquoi cette projection est utile ?

Cette représentation permet d'observer rapidement quels pays se ressemblent, lesquels s'opposent, et lesquels sortent du groupe. Elle constitue une première lecture visuelle de la structure du dataset avant l'application des méthodes de clustering (CAH, K-Means),



En clair :

Le plan factoriel transforme les résultats de l'ACP en carte lisible. Il aide à repérer des groupes naturels de pays, des profils atypiques et les grands contrastes du dataset, ce qui facilitera ensuite l'interprétation des clusters.

Classification hiérarchique : principe et dendrogramme



La classification hiérarchique ascendante (CAH) est appliquée sur les quatre axes ACP retenus, qui résument 81,73% de l'information initiale.

Chaque pays commence seul, puis les regroupements se font étape par étape jusqu'à former une hiérarchie complète.




Principe de la CAH

- Départ : 1 pays = 1 groupe
- Calcul des distances entre pays ou groupes
- Fusion progressive des éléments les plus proches
- Construction d'une arborescence de regroupement
- Méthode utile pour explorer la structure des données



Lecture du dendrogramme

- Chaque branche traduit un regroupement progressif
- Une fusion basse indique des profils proches
- Une fusion haute indique des groupes plus différents
- Une coupe horizontale aide à fixer le nombre de clusters
- Les grandes ruptures visuelles orientent le choix final



Pourquoi utiliser la CAH avant K-Means ?


- Visualiser les proximités entre pays
- Comparer plusieurs niveaux de regroupement
- Aider au choix du nombre de clusters
- Fournir une base de validation avant la segmentation finale



En clair : La CAH permet de voir comment les pays se ressemblent avant de les segmenter définitivement. Le dendrogramme sert donc de guide pour choisir un nombre de groupes pertinent, lisible et cohérent,


Classification hiérarchique : principe et dendrogramme 2/2

Dendrogramme complet de la classification ascendante hiérarchique



Choix de 4 clusters avec la CAH

Selection of 4 clusters using hierarchical clustering



Pourquoi 4 clusters ?

- Grande rupture visible avant les dernières fusions
- 4 groupes offrent une lecture claire et stable
- Bon compromis entre détail et lisibilité
- Base cohérente pour comparer les profils pays



Ce que montre la CAH

- Plusieurs valeurs de k autour du découpage observé
- La compacité des groupes obtenus
- La lisibilité et la séparation entre clusters
- La cohérence métier des regroupements formés



Lien avec la suite

- Le choix de 4 clusters sera repris pour K-means
- Cela permet de comparer une logique hiérarchique et une logique de partition
- Les groupes seront ensuite décrits à l'aide des variables métier

Pourquoi ne pas choisir trop ou trop peu de groupes ?



Trop peu :
Groupes trop larges



Trop de groupes :
lecture trop fragmentée



4 groupes : compromis
pertinent



Décision guidée par la
structure des distances


En clair :



La CAH permet de repérer un découpage naturel du dataset. Ici, la coupe en 4 clusters est retenue car elle offre une segmentation à la fois lisible, cohérente et adaptée à la suite de l'analyse avec K-means.

K-means : validation du nombre de clusters

Méthode du coude - K-means



Lecture rapide

K = 2 → groupe trop large

K = 4 → compromis retenu

K = 5+ → gain supplémentaire plus limité et lecture plus fragmentée



Pourquoi valider avec K-means ?

- Obtenir une segmentation finale plus stable
- Vérifier que le découpage issu de la CAH reste cohérent
- Former des groupes compacts et comparables
- Préparer une classification exploitable pour le profilage des pays



Ce qu'on compare

- Plusieurs valeurs de k autour du découpage observé
- La compacité des groupes obtenus
- La lisibilité et la séparation entre clusters
- La cohérence métier des regroupements formés



Résultat retenu

La solution à 4 clusters est retenue. Elle reste cohérente avec la CAH, limite la fragmentation des groupes et fournit une segmentation exploitable pour le profilage des pays.




En clair :

K-means sert ici à confirmer et stabiliser le nombre de groupes avant l'interprétation finale. Dans ce projet, 4 clusters constituent le meilleur compromis entre cohérence statistique, lisibilité des profils pays et exploitabilité business.

Modèle K-means retenu

Projection des clusters K-means sur PC1 / PC2



Modèle retenu



- K-means avec 4 clusters
- 125 pays classés
- 4 axes ACP utilisés
- Résultat stocké dans cluster_kmeans

Répartition obtenue



- Cluster 1 : 20 pays
- Cluster 2 : 8 pays
- Cluster 3 : 54 pays
- Cluster 4 : 43 pays



Lecture du graphique

Les pays proches appartiennent à des profils similaires.
Les clusters les plus à droite correspondent à des pays plus marqués par les variables économiques, de production ou d'échanges.



En clair :

Le K-means confirme l'existence de plusieurs profils pays.
La solution à 4 clusters reste cohérente avec la CAH et fournit une base exploitable pour le profilage métier.

Comparaison CAH et K-means




La CAH et le K-means poursuivent ici le même objectif : structurer les pays en groupes homogènes. La CAH sert d'outil d'exploration et de choix, tandis que le K-means fournit la segmentation finale retenue

Comparaison des logiques de clustering : CAH vs K-means




CAH : Logique Hiérarchique

- Regroupe progressivement les pays selon leur proximité
- Produit un dendrogramme lisible
- Sert surtout à explorer la structure de données
- Aide à choisir un nombre pertinent de clusters
- Dans ce projet : elle suggère une solution en 4 groupes



Sortie principale : une hiérarchie de regroupements

K-means : logique de partition



Sortie principale : une partition finale en 4 clusters



K-means : Logique de partition

- Répartit directement les pays dans k groupes
- Cherche des groupes compacts et séparés
- Demande de fixer k à l'avance
- Sert à obtenir une classification finale exploitable
- Dans ce projet : il confirme et stabilise la solution à 4 clusters

	CAH	K-means
 Principe	Regroupement progressif	Partition directe
 Paramètre clé	Lecture du dendrogramme	Choix de k
 Rôle dans le projet	Guide le choix	Valide et segmente
 Résultat	4 groupes suggérés	4 clusters retenus



Pourquoi utiliser les deux ?

- Croiser une logique hiérarchique et une logique de partition
- Vérifier que le découpage en 4 groupes reste cohérent
- Obtenir une lecture plus robuste des profils pays
- Préparer une profilage métier clair et exploitable




En clair :

La CAH à repérer le bon découpage, puis le K-means transforme ce choix en segmentation finale. Dans ce projet les deux méthodes convergent vers 4 groupes, ce qui renforce la cohérence et la crédibilité du résultat,

Profil moyen des clusters

Profil moyen standardisé des clusters K-means



Lecture des profils

- **Cluster 1** : Profil plutôt exportateur, peu dépendant des importations, mais avec une stabilité politique et un niveau de vie plus faible,
- **Cluster 2** : Profil le plus puissant économiquement; forte disponibilité intérieure, importation élevées, production forte et PIB élevé.
- **Cluster 3** : Groupe le plus fragile; faibles niveaux sur la plupart des indicateurs économiques et alimentaires.
- **Cluster 4** : Pays plus stables, avec un PIB par habitant et une disponibilité alimentaire élevé, mais des volumes globaux plus modestes.



Comment lire la heatmap ?

- Valeur positive : niveau supérieur à la moyenne
- Valeur négative : Niveau inférieur à la moyenne
- Chaque ligne représente un cluster
- La standardisation permet de comparer des variables de nature différente



Taille des groupes

- Cluster 1 : 20 pays
- Cluster 2 : 8 pays
- Cluster 3 : 54 pays
- Cluster 4 : 43 pays




En clair :

Cette heatmap transforme les résultats K-means en **profils compréhensibles**. Elle permet de voir rapidement quels groupes sont **les plus solides**, **les plus fragiles**, **les plus stables** ou **les plus dépendants des importations**. C'est une étape essentielle pour passer d'un résultat statistique à une **lecture métier exploitable**.



Score d'attractivité et groupes à prioriser



Critère du score

- 30% : Dépendance aux importations
- 25% : PIB par habitant
- 20% : Stabilité politique
- 15% : Volume d'importation
- 10% : Disponibilité alimentaire en quantité



Groupes à prioriser

Priorité 1 :

- Cluster 2
- Score moyen le plus élevé : 0,64
- Profils attractifs comme le Japon, L'Allemagne, le Royaume-Uni, L'Arabie Saoudite, la France
- Marchés structurés, importateurs et solvables

Priorité 2 :

- Cluster 4
- Score moyen positif 0,42
- Profils intéressants comme le Luxembourg, l'Irlande, la Suisse et le Danemark
- Groupe complémentaire plus large et stable

Lecture business

Le cluster 2 apparaît comme la cible principale : il combine les meilleurs niveaux d'attractivité moyenne, des volumes d'importations importants et un niveau économique favorable. Le cluster 4 constitue une cible secondaire pertinente pour élargir l'analyse à des marchés stables et solvables.



En clair :

Le COMEX devrait concentrer ses efforts sur le **cluster 2** puis approfondir le **cluster 4** comme groupe complémentaire. Le score d'attractivité sert à hiérarchiser les groupes de pays avant la recommandation finale.

Synthèse finale et recommandation COMEX



1. Ce que l'analyse nous a appris



- **L'ACP** a permis de résumer l'information du dataset en 4 axes explicatifs (81,73% de variance cumulée)



- **La projection** des pays a révélé des profils variés et des oppositions claires entre pays



- **La CAH** a mis en évidence une structure naturelle des regroupements



- **Le K-means** avec 4 clusters a été validé et fournit une segmentation stable et exploitable



- **Les clusters** ont des profils différenciés sur les dimensions économiques, commerciales et politiques

2. Recommandation stratégique



Prioriser les pays du **CLUSTER 2**
Pour une étude approfondie et un plan d'entrée sur le marché

Pourquoi le Cluster 2 est prioritaire ?

- ✓ Profils favorables : niveaux économiques et commerciaux élevés, capacité de marché importante
- ✓ Volumes d'importations élevés et marchés déjà ouverts aux échanges internationaux
- ✓ Stabilité politique relativement bonne
- ✓ Groupe restreint, facilitant une analyse détaillée pays par pays

En parallèle

- Garder le Cluster 4 comme cible secondaire (pays à fort potentiel mais plus hétérogènes / risqués)
- Surveiller le Cluster 3 pour les opportunités spécifiques (fort potentiel mais dépendance plus élevée)



3. Pays à prioriser (exemples)

Exemples de pays du cluster 2 à étudier en priorité



Allemagne, Royaume-Uni, Japon, Afrique du sud, Mexique, Russie, Arabie Saoudite, France

4. Impact attendu pour La Poule qui Chante



Concentrer les ressources commerciales sur les marchés les plus attractifs



Réduire les risques d'échec en s'appuyant sur des données objectives



Accélérer le développement international de La Poule qui Chante



Maximiser le retour sur investissement à l'international

En clair :

Notre analyse identifie des marchés à fort potentiel statistique au regard des critères retenus. La recommandation est de lancer en priorité l'étude des pays du Cluster 2, tout en gardant une veille sur les autres opportunités



Objectif COMEX :

Donner une base solide et actionnable pour réussir l'expansion internationale



Compétences mobilisées et posture data analyst



Compétences techniques

- Nettoyage et structuration des données
- Jointures, pivot et création de variables dérivées
- Analyse exploratoire et visualisations
- ACP, CAH et K-means
- Construction d'un score d'attractivité



Méthode de travail

- Partir du besoin business avant les méthodes
- Vérifier la qualité et la cohérence du dataset
- Choisir les outils statistiques adaptés au problème
- Interpréter les résultats dans une logique métier
- Transformer l'analyse en recommandations exploitables

Objectif : Passer des données à la décision



Communication des résultats

- Vulgarisation des notions techniques
- Slides lisibles et visuelles
- Mise en avant des messages clés
- Capacité à justifier les choix méthodologiques
- Synthèse orientée COMEX



Posture Data Analyst

- Rigueur dans la préparation des données
- Esprit critique face aux résultats
- Capacité à relier statistique et enjeux métier
- Autonomie dans l'analyse
- Pédagogie pour rendre les conclusions compréhensibles
- Aide à la décision sans surinterpréter



En clair :

Ce projet montre qu'un Data Analyst ne se contente pas d'appliquer des méthodes. Il doit préparer les données, choisir les bons outils, interpréter les résultats avec recul, puis les restituer de façon simple, claire et utile pour la décision.